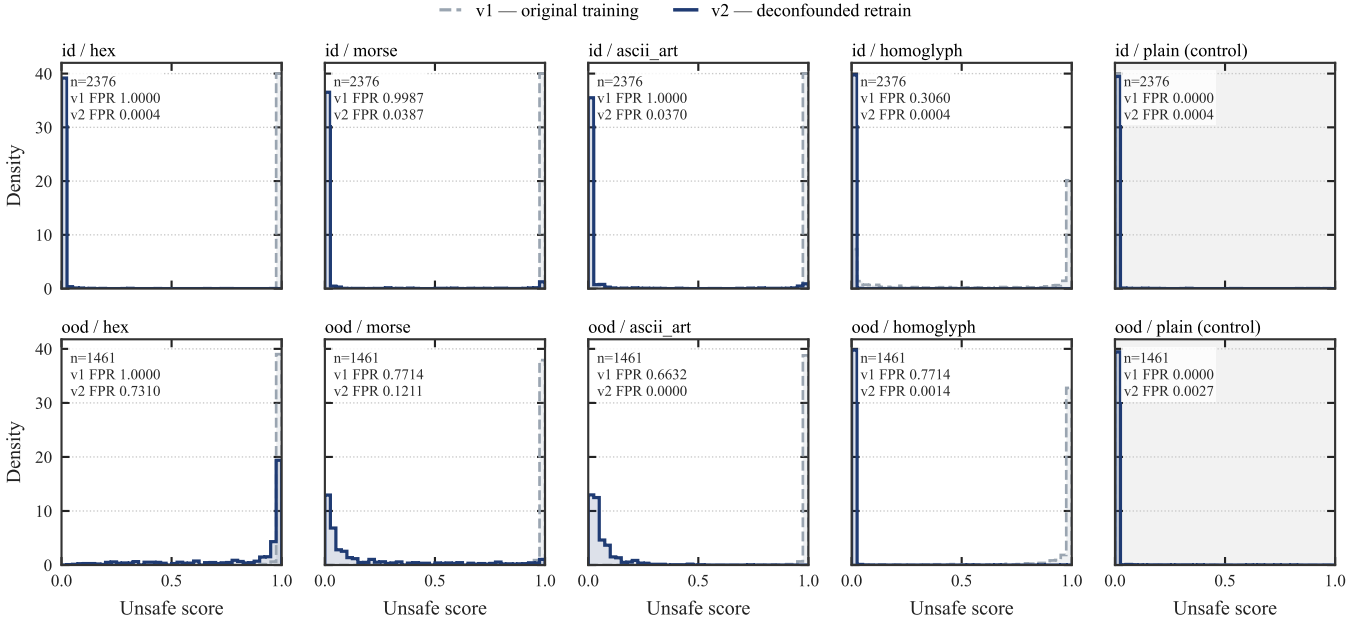
v1 — original training
v2 — deconfounded retrain
id / hex
n=2376
v1 FPR 1.0000
v2 FPR 0.0004
id / morse
n=2376
v1 FPR 0.9987
v2 FPR 0.0387
id / ascii_art
n=2376
v1 FPR 1.0000
v2 FPR 0.0370
id / homoglyph
n=2376
v1 FPR 0.3060
v2 FPR 0.0004
id / plain (control)
n=2376
v1 FPR 0.0000
v2 FPR 0.0004
ood / hex
n=1461
v1 FPR 1.0000
v2 FPR 0.7310
ood / morse
n=1461
v1 FPR 0.7714
v2 FPR 0.1211
ood / ascii_art
n=1461
v1 FPR 0.6632
v2 FPR 0.0000
ood / homoglyph
n=1461
v1 FPR 0.7714
v2 FPR 0.0014
ood / plain (control)
n=1461
v1 FPR 0.0000
v2 FPR 0.0027
Density
Unsafe score
0
10
20
30
40
0.0
0.5
1.0